

à apprendre 0 ,1 ,2,3 2411

Carte de kohonen

SAY Ahoussi Armand

Fevrier 2017

1 Introduction

Ce TP va nous permettre de manipuler les cartes de Kohonen ou encore cartes auto adaptatives. Ce type de reseau de neurone va nous permettre de reduire la dimension des données à analyser sans tout de fois séparer les données en hyperplan comme dans le cas des neurones formels ou a perceptron multicouches. Nous rapellons que les cartes de Kohonen sont des reseaux de neurone en apprentissage non supervisé et par conséquent les different pattern n ' ont pas de labelles.




Figure 1: Carte de Kohonen

2 Mise en place d une carte de Kohonen sous Matlab

2.1 ALgorithme d apprentissage

L ' algorithme d' apprentissage est itératif et compétitif en se sens que la mise a jours des poids synaptique dans ce reseau de neurone repose sur le choix d' un neurone gagnant. L algorithme se presente comme suit:

A chaque itération on presente un patern $x(x_1, x_2, x_3, \dots, x_n)$ dans l'ensemble des patterns X en entrée du reseau. On déternine ensuite le neurone gagnant $w(w_1, w_2, w_3, \dots, w_n)$ par la maximisation de la distance euclidienne

$$d = \sqrt{\sum_{i=1}^n (x_i - w_i)^2}$$

Le neurone gagnant w^* dans l ensemble des neurone W est donc definit de la sorte :

$$w^* = \sup_{w \in W} (d)$$

Une fois le neurone gagnant w^* déterminé la mise a jour des poids des neurones se fait au travers d' une mesure de voisinage

$$\alpha(i^*, j) = \alpha(t) \exp\left(-\frac{d_t^2(i^*, j)}{2\alpha^2(t)}\right)$$

$d_t^2(i^*, j)$ étant la distance topologique entre neurone gagnant $w^*(y_{i1}, y_{i2}, \dots, y_{in})$ et un neurone $w_j(y_{j1}, y_{j2}, \dots, y_{jn})$ appartenant au voisinage de w^* .on definit la distance topologique de la meme facon que la distance euclidienne par :

$$d_t(i^*, j) = \sqrt{\sum_{k=1}^n y_{ik} y_{jk}}$$

l ' actualisation des poids de chaque neurone se fera donc de la facon suivante pour chaque neurone avec x le pattern en entrée :

$$w_{t+1} = w_t + \alpha(i^*, j)\eta(t)(w_t - x)$$

Quelques remarques importantse sont importantes a faire :

- $\eta(t)$ la fonction d influence temporelle decroit linéairement pa rapport au temps
- $\alpha(t)$ la fonction d influence laterale decroit lineairement par rapport au temps
- les poids des neurone sont initialisés aléatoirement entre $[0 \ 1]$
- la topologies des neurone est un carrée dans lequel les neurones sont séparés régulièrement .On repete le processus de mise a jour des poids avec l ensemble des donnée d apprentissage.

2.2 verification de l'implémentation

Pour tester notre implémentation on fixe l'espace des patrons à la dimension 2, on initialise 1000 patrons répartis sur l'espace 2D $[0.25, 0.75] \times [0.25, 0.75]$ et on lance la simulation. Les observations sont les suivantes :
à $t=0$ l'espace des données encadré en rouge




Figure 2: $t = 0$




Figure 3: $t=100$




Figure 4: $t=300$

ensuite de 600 à 1000




Figure 5: $t=613$

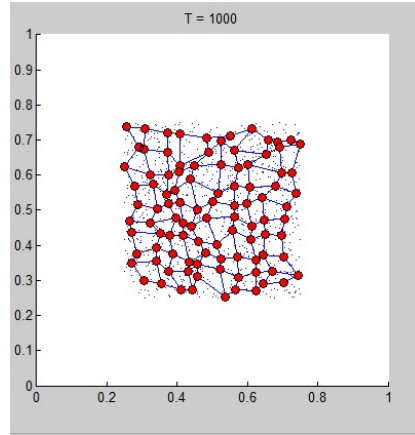


Figure 6: $t=1000$

On observe un déploiement progressif de la carte de Kohonen sur l'espace des données. Cela s'explique par le fait qu'au fur et à mesure du temps les poids $w(t)$ des neurones vont converger vers les patrons x plus proches au sens de la distance euclidienne. On obtient donc une concentration de neurones dans les endroits où les patrons sont plus concentrés.

3 Simulation

3.1 simulation de jeux de données artificielle

L'objectif est d'observer le dépliement de la carte de Kohonen en fonction des différents paramètres de l'algorithme. Pour cela, on génère 1000 patrons dans le rayon centré en $(0.5, 0.5)$. Selon les coordonnées polaires en notant r la distance du centre au rayon du disque et l'angle entre l'horizontale et le rayon et le segment $[r]$, On choisira pour la simulation :

$$r \sim U[0, 0.5]$$

$$\theta \sim U[0, 2\pi]$$

on obtient alors pour l'initialisation des patrons dans le repère cartésien :

$$x = r \cos(\theta) + 0.5$$

$$y = r \sin(\theta) + 0.5$$

3.1.1 Phénomènes observés lors de l'apprentissage

En lançant plusieurs fois l'apprentissage, on observe 2 phénomènes dans le processus de convergence de la carte de Kohonen :

- De grand écart de changement dans l'air de la carte de Kohonen dans les débuts de l'apprentissage




Figure 7: $t = 18$




Figure 8: $t=73$




Figure 9: $t=123$

- Dilation (augmentation progressive) de la surface jusqu'à la convergence à partir d'un grand nombre de patterns appris




Figure 10: $t = 393$




Figure 11: $t=633$




Figure 12: $t=808$

Ces phénomènes observés sur la carte de Kohonen s'explique par le fait que au debut de l'apprentissage les poids se mette a jour progressivement avec un de grand coefficient d'influence laterale $\eta(t)$ et d'interaction temporelle $\alpha(t)$ donc beaucoup de neurones voit leur poids se modifier. Ainsi pour de grande iteration du temps seul une minaurité de neurones voisin sont modifié dû aux faible valeur de $\eta(t)$ et $\alpha(t)$. On observe donc plus de modification locaux des poids que de modification glogaux des poids des neurones.

3.1.2 Effet des bornes de taux d'apprentissage et de zone d'influence dans la modification des poids

- Pour de très faible valeur du taux de zone d'influence $\alpha(t)$ peu de neurone sont modifiés ce qui ne permet pas au réseaux d'être appris correctement il reste pratiquement au même état que lors de l'initialisation des poids.

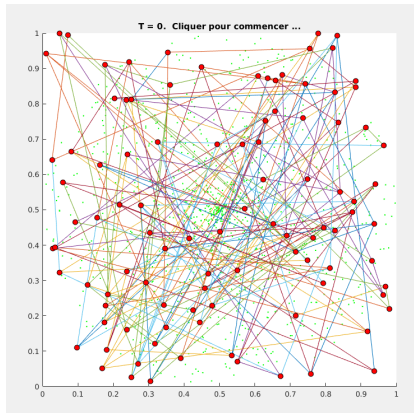


Figure 13: a $t=0$ $\alpha_{max} = 0.4$




Figure 14: $t= 1000$ $\alpha_{min} = 0.1$

Pour de très faibles valeurs de $\eta(t)$ taux d'apprentissage le réseaux de neurone est appris très vite on ne passe pas par des période de transition longue comme

dans le cas 3.1.1 la carte se déploie letement jusqu ' à recouvrir toute la surface du cercle de patterns




Figure 15: $t = 144$




Figure 16: $t=588$




Figure 17: $t=1000$

Pour te très grande valeur de η et α l Algorithme d apprentissage diverge tout simplement ou ne coverage pas dans la region de l espace des patterns
On conclut qu il existe des intervalle pour η et α pour lesquelles le reseau de neurone converge effacement.

3.1.3 Augmentation du nombre de patterns à 10000

Pour un très grand nombre de patterns l algorithme devient très lent mais coverge tout de meme au bout d' un temps tres inferieur à 10000 cela met en jeux la notion du nombre de patterns a mettre en apprentissage pour apprendre le réseaux.Ce nombre de pattern doit donc etre optimal.Il y a donc un surapprentissage dans notre cas.

3.1.4 reduction du nombre de pattern à 100

On présente 100 patterns à l ' entrée de notre réseaux le résultat nous presente une carte de kohonen qui ne se deploie pas entièrement sur toute la surface de notre espace de pattern mais on a une convergence de l algorithme d apprentissage on vois dans ce cas qu on est bien en sous apprentissage de notre réseau.




Figure 18: $t = 144$

On conclut donc que ces réseaux peuvent être efficace et nous aider a caractériser nos données seulement si on lui met en parametre des données optimale pour sa convergence.

3.1.5 données uniforme sur le disque

A présent on reparti les données uniformement sur le disque les resultat obtenu sont les suivants:




Figure 19: données uniforme $t = 1000$

Les neurones sont disposés presque à égale distance de chacun dans l'espace de représentation des patterns et sont donc repartis de façon uniforme aussi.

3.2 carte de Kohonene mono-dimensionnelle

Comme dans le cas de la carte de kohonen bidimensionnelle nous allons analyser le comportement de la carte de Kohonen monodimensionnel .

Les resultats sont quasi identiques à ceux observés avec la carte de Kohonen bidimensionnelle la seule difference reside dans le fait pour pouvoir avoir une bonne représentation spaciale des donnée il faut augmenter le nombre de neurones au même titre que celui de la carte bidimensionnelle.

On peut bien evidemment obtenir une ditribution pour la ficelle de Kohonen ci-dessous , il faudra alor bien segmenter l'ordre de presentation des patterns

aux réseau de telle sorte qu ' on presente les patterns du centre à la périphérie du cercle.




Figure 20: ficelle parfaitement distribuée

On étudie maintenant trois jeux de données dont la distribution des patterns auront un effet sur la carte de Kohonen résultante




Figure 21: effet de présentation des patterns




Figure 22: effet de distribution des patterns




Figure 23: xor

La carte de Kohonen obtenue en figure 21 témoigne de l'ordre de présentation des patterns au réseau de neurone. Sachant que le coefficient d'influence latérale α diminue au cours du temps, si l'on ne présente que les patterns au dessus de la droite ($y=0.5$) en premier lieu le réseau ne sera pas distribué équitablement dans le plan. Car les points du plan inférieur auront une faible capacité à attirer beaucoup de voisins. Si l'on décide alors de distribuer les données inégalement, c'est plutôt l'effet de groupe qui l'emporte (figure 22). Le réseau est donc dense ou il a plus de concentration de points. Pareil aussi avec le XOR, c'est l'effet de présentation qui l'emporte.

On conclut donc pour faire une bonne classification, il faut présenter les données de façon uniforme et variée dans l'espace de représentation.

4 Application à la base des chiffres manuscrits

On utilisera par la suite une carte de Kohonen de dimension 2 avec les patterns X de taille (16 X 16), les poids seront donc de taille (16X16) constituant eux-même des images qui seront utilisées pour la reconnaissance de caractère après l'apprentissage.

On met donc en place les routines Matlab pour cela et on obtient pour la représentation combinée des patterns sur l'image suivante.



Figure 24: patterns de manuscrit à apprendre 0,1,2,3

Avec l'algorithme d'apprentissage exécuté plusieurs fois sur les patterns on

obtient la carte de Kohonen suivante :




Figure 25: Carte de Kohonen issue de l'apprentissage

Dans le déroulement de l'algorithme d'apprentissage on observe le remplissage de tous les éléments de la carte d'abord par le chiffre 0 et ainsi de suite une répartition des autres chiffres sur l'ensemble de la surface. Cela s'explique par le fait qu'au départ c'est le pattern "0" qui est présenté donc tous les poids se rapprochent de "0" naturellement et ainsi de suite pour les autres patterns.

4.1 Quelle stratégie pour la classification des manuscrits

On pourrait donc décomposer l'espace des poids synaptiques en 4 classes ou même étiqueter les poids correspondant en les attribuant des classes. Pour tout pattern présenté à l'entrée on calculera la distance euclidienne entre lui et les poids on choisira donc la classe du pattern de test par la classe du neurone synaptique le plus proche.

On effectue l'entraînement sur les données d'entraînement et l'on teste la carte de Kohonen obtenue avec les données de test de base de pattern différent. Le résultat est le suivant.



Figure 26: Pattern de test



Figure 27: resultats

On constate Que l'algorithme a reconstitué les caractères manuscrits avec un faible taux d'erreur ce qui est quand même acceptable
on décide maintenant d'effectuer l'apprentissage et la reconnaissance avec la même base de patterns .



Figure 28: Pattern de test



Figure 29: resultats

On constate qu'il n'y a pas grande différence et les taux d'erreur sont quasiment les mêmes, on conclut donc qu'une fois l'apprentissage fait les résultats des tests avec les patterns différents mais avec les mêmes données à classer sont les mêmes.

5 Conclusion

Ce TP nous a permis de manipuler les cartes de Kohonen et de les utiliser pour résoudre des problèmes de reconnaissance de forme. Cependant pour que l'apprentissage puisse bien se faire il faut penser à bien calibrer les paramètres du réseau et présenter les patterns de façon régulière et équilibrée sur l'espace de représentation sinon les résultats obtenus ne permettent pas de caractériser de façon efficace les données.